



北京科技大学
University of Science and Technology Beijing

超越压缩感知: 扩散模型实现 非完整观测雷达参数重建

计算机与通信工程学院 黄天耀

2026年1月

个人情况



职业

2023–至今	北京科技大学–计算机与通信工程学院	教授
2017–2023	清华大学–电子工程系	助理研究员
2014–2017	中航工业集团机载雷达所(607所)	工程师/团队负责人

教育

2009–2014	清华大学	电子工程系	博士
2005–2009	哈尔滨工业大学	通信工程系	本科

汇报提纲

1

背景：非完整观测下场景重建

2

方法：扩散模型及其应用

3


结果：效果对比

4

总结与展望

雷达回波模型

SAR成像示意图



平动补偿后，雷达回波

$$y[n, m] = \gamma_{\omega} \exp(-j2\pi f_{rg}n) \exp(j2\pi f_{az}m)$$

RCS

径向
距离

方位
多普勒

模型适用于其它雷达探测场景

信号处理：线性逆问题求解

❖ 回波模型改写为线性方程 $y[n, m] = \gamma_{\omega} \exp(-j2\pi f_{rg}n) \exp(j2\pi f_{az}m)$

$$y = \Phi x$$



非完整观测下的挑战：欠定问题求解

❖ 适定问题：观测数量等于未知个数，


$$y = \Phi x, \Phi \in \mathbb{C}^{NM \times NM}$$

❖ 欠定问题：观测数量少于未知个数，

$$y = \Phi x, \Phi \in \mathbb{C}^{N'M' \times NM}, N'M' < NM$$

❖ 传统匹配滤波方法

雷达回波 $y \in \mathbb{C}^N$ “模板” $\phi \in \mathbb{C}^N$




$$\hat{x} = \Phi^H y$$

1. 求内积确定与“模板”的相似程度
 2. 挑选相似度高的“模板”
- ✗ “模板”之间不正交，相互串扰




高旁瓣掩盖弱目标

❖ 旁瓣示意



原始图像



非完整观测下
匹配滤波结果

欠定问题求解的思路：引入先验信息

- ❖ 精确求解欠定方程：精确重建场景，没有旁瓣、没有目标能量损失
- ❖ 途径：引入场景的先验信息，压缩感知

- ❖ 压缩感知方法：稀疏先验

场景中只有少量散射点

$$\min_x \|y - \Phi x\|_2^2 + \lambda \|x\|_1$$

似然项


先验项

稀疏场景下，具备理论性能保证



场景不稀疏怎么办？

- ❖ 不稀疏场景下恢复结果：



原始图像

非完整观测下
压缩感知结果

汇报提纲

1

背景：非完整观测下场景重建

2

方法：扩散模型及其应用

3

结果：效果对比


4

总结与展望

解决不稀疏场景的思路：引入复杂先验信息

压缩感知方法

$$\min_x \|y - \Phi x\|_2^2 + \lambda \|x\|_1$$



稀疏先验

深度学习方法

$$\min_x \|y - \Phi x\|_2^2 + f(x)$$

复杂先验

贝叶斯学习的视角

最大后验概率估计:

$$\begin{aligned}\hat{\mathbf{x}} &= \arg \max_{\mathbf{x}} p(\mathbf{x} | \mathbf{y}) \\ &= \arg \max_{\mathbf{x}} p(\mathbf{y} | \mathbf{x}) p(\mathbf{x}) \\ &= \arg \min_{\mathbf{x}} \mathcal{L}(\mathbf{x}; \mathbf{y}) + f(\mathbf{x}),\end{aligned}$$

似然项

$$\mathcal{L}(\mathbf{x}; \mathbf{y}) = -\log p(\mathbf{y} | \mathbf{x}) = \|\mathbf{y} - \mathbf{\Phi}\mathbf{x}\|_2^2$$

先验项

$$f(\mathbf{x}) = -\log p(\mathbf{x})$$

场景的先验分布

复杂先验信息的学习和利用

学习阶段：获得先验概率分布


复杂先验，**非解析**描述

$$f(x) = ?$$

利用阶段：求解正则优化问题

$$\min_x \|y - \Phi x\|_2^2 + f(x)$$

没有解析表达式的优化问题，怎么求解？



图片来源：张毅


Landscape of $f(x)$

回顾：生成式模型Generative AI

生成式模型大爆发：Sora、ChatGPT/Deepseek


生成式模型的目标：给定特定特征的样本， $X_1, X_2, \dots, X_N \sim p_{\text{data}}$

生成符合该特征的样本： $X \sim p_{\text{data}}$



回顾：扩散模型

基本思想



图片来源：互联网


训练过程：从数据中，学习获得一组神经网络参数

扩散模型与逆问题求解

❖ 生成新样本


- 训练阶段：优化神经网络

Reverse Process



- 采样阶段：生成符合分布的样本

Reverse Process



随机噪声

新样本

❖ 复杂先验学习与利用

- 学习阶段：获得先验概率分布





$$f(x) = ?$$

- 利用阶段：求解正则优化问题


$$\min_x \|y - \Phi x\|_2^2 + f(x)$$

所采用的方法：先验学习阶段

Forward process
$$d\mathbf{x}_t = -\frac{1}{2} \beta(t) \mathbf{x}_t dt + \sqrt{\beta(t)} d\mathbf{B}_t$$




SAR Distribution



Noise

Reverse process
$$d\mathbf{x}_t = -\beta(t) \left[\frac{1}{2} \mathbf{x}_t + \nabla \log p_t(\mathbf{x}_t) \right] dt + \sqrt{\beta(t)} d\bar{\mathbf{B}}_t$$

score function



所学网络：
先验分布的下降梯度

所采用的方法：先验利用阶段

❖ 待求解的问题

$$\min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2^2 + f(\mathbf{x})$$

❖ 挑战：无先验项 $f(\mathbf{x})$ 的解析表达式，但其梯度 $\nabla f(\mathbf{x})$ 由神经网络表达

❖ Langevin Dynamics

一种蒙特卡洛采样方法

$$\mathbf{x}^* = \mathbf{x} + \epsilon \nabla \log p(\mathbf{x} | \mathbf{y}) + \sqrt{2\epsilon} \mathbf{w}$$

梯度下降+随机游走

下降方向：从数据中学习

❖ Proximal Sampling

似然项

$$q(\mathbf{z} | \mathbf{x}) \propto \exp \left(-\mathcal{L}(\mathbf{z}; \mathbf{y}) - \frac{1}{2\lambda^2} \|\mathbf{x} - \mathbf{z}\|^2 \right),$$

先验项

$$q(\mathbf{x} | \mathbf{z}) \propto \exp \left(-f_{\theta}(\mathbf{x}) - \frac{1}{2\lambda^2} \|\mathbf{x} - \mathbf{z}\|^2 \right).$$

X. Xu and Y. Chi, “Provably robust score-based diffusion posterior sampling for plug-and-play image reconstruction,” Advances in Neural Information Processing Systems, vol. 37, pp. 36 148–36 184, 2024.

汇报提纲

1

背景：非完整观测下场景重建

2

方法：扩散模型及其应用

3

结果：效果对比

4

总结与展望


合成数据结果

MNIST图像集


随机复数相位

下采样:
 $32 \times 32 \rightarrow 24 \times 24$


SNR = 2 dB




原始图像




匹配滤波结果




压缩感知FISTA结果



现有Diff方法



所提Diff方法I



所提Diff方法II

合成数据结果，定量指标

MNIST图像集

随机复数相位

下采样：
 $32 \times 32 \rightarrow 24 \times 24$

SNR = 2 dB

成像质量指标

旁瓣水平指标

Method	NMSE ↓	PSNR ↑	SSIM ↑	LPIPS ↓	MPSLR ↓	MISLR ↓
MF	2.71	8.83	0.299	0.689	-4.46	-0.189
FISTA	-2.28	13.4	0.347	0.324	-7.73	-12.1
ADMM	-2.23	13.4	0.318	0.348	-8.04	-12.2
DPS	-3.02	15.7	0.511	0.435	-5.37	-6.68
SGS-DDPM	-5.49	23.5	<u>0.789</u>	<u>0.0360</u>	<u>-11.0</u>	<u>-23.7</u>
SGS-DDIM	<u>-5.31</u>	<u>23.2</u>	0.900	0.0321	-11.2	-26.0


合成数据结果，定量指标

MNIST图像集


随机复数相位

完整尺寸：
 32×32

积分旁瓣比



随信噪比变化




随观测完整性变化

Sentinel-1 A SAR图像结果


部分山区图像

下采样:
 $256 \times 256 \rightarrow 192 \times 192$


SNR = 2 dB




原始图像




匹配滤波




压缩感知FISTA



现有Diff方法



所提Diff方法I




所提Diff方法II

Sentinel-1 A SAR图像结果


部分山区图像

下采样:
 $256 \times 256 \rightarrow 192 \times 192$


SNR = 2 dB




原始图像




匹配滤波




压缩感知FISTA



现有Diff方法



所提Diff方法I



所提Diff方法II

汇报提纲

1 背景：非完整观测下场景重建

2 方法：扩散模型及其应用

3 结果：效果对比

4 总结与展望

总结与展望

❖ AI for 雷达探测中的逆问题求解

- 为什么使用AI：先验复杂，难以使用解析表达
- 相比端到端的优势：
 - 可解释性，物理约束（观测模型）+数据驱动（场景先验）
 - 适应不同波形、阵列流形，更少的训练样本
 - 算法渐近收敛性的理论保证[Xu2024]
- 性能优势
 - 复杂场景下，更高的场景重建精度，更低副瓣

总结与展望

❖ SAR成像→更多探测场景

- 运动平台下视杂波抑制，杂波非稀疏、先验分布复杂
- 长相参积累、机动目标检测，目标RCS、运动轨迹等先验分布复杂

❖ 参数估计→目标检测

- 不仅要重建场景，还要计算置信区间

❖ 高精度重建→高分辨重建

- 用数据换成本

❖ 观测模型已知→观测模型部分已知